Результаты исследования поиска целых чисел

Task 3 · Research Methods · Software Engineering

Авторы: Кожахмет Медетбек и Джазбаев Айбар
Дата сбора: 5 ноября 2026 года
Репозиторий: github.com/Medetkb/integer-membership-benchmark

Цель и основной результат

Исследование продолжает Task 2 и сравнивает повторный поиск целых чисел в заранее созданных Python list и set. Основной вопрос: снижает ли set типичное время одного поиска более чем на 20% при 10 000 ключей и 50% попаданий, сохраняя корректность и укладываясь в 8 MiB отслеживаемых выделений памяти?

В основном условии медианное парное ускорение составило **822.78 раза**; 95% бутстреп-интервал: 812.66-829.02. Медианное снижение времени - 99.878%. Ошибок корректности не зафиксировано. Вывод относится к этому компьютеру и заданному протоколу.

Дизайн эксперимента

Измерения выполнены на Apple M3, 8 GiB RAM, native macOS, CPython 3.12.14. Версия интерпретатора и параметры исследования совпадают с Task 2. Изменение инструмента состоит в сохранении фактических записей прогрева, фазы и времени записи; измеряемая функция и границы таймеров сохранены.

Параметр	Значение
Размер коллекции	100, 1 000 и 10 000 уникальных целых чисел
Доля попаданий	0%, 50%, 100% - всего 9 условий
Наборы данных	30 seed на условие, номера 101-130
Один замер	1 000 запросов, повторённых 10 раз: 10 000 поисков
Прогрев и оценка	2 пары прогрева и 8 рабочих пар на seed
Порядок методов	Сбалансирован и перемешан; одинаковый workload SHA256
Собранные данные	270 процессов; 1 080 warmup + 4 320 benchmark строк

Время создания контейнера измерено отдельно. Запись логов, генерация данных и отслеживание памяти исключены из таймера поиска. Сбор завершился за 253,7 секунды. Рабочие приложения оставались открыты; изоляция фоновой нагрузки и частоты CPU не выполнялась.

Обработка и статистические единицы

Из 5 400 строк JSONL исключены только 1 080 строк с phase=warmup. Проверены полнота всех условий, seed и повторов, отсутствие дублей, совпадение парных наборов и корректность числовых полей. IQR-правило отметило 212 выбросов; все они оставлены в анализе.

Для каждого seed рассчитывается медиана восьми рабочих замеров. Далее статистика строится по 30 таким значениям, а не по 240 техническим повторам как независимым наблюдениям. 95% интервалы медианы получены 10 000 бутстреп-перевыборками seed с возвращением; random seed=42.

В таблице приведены медиана и интерквартильный диапазон p25-p75. Единица времени - нс/поиск. Это среднее время поиска внутри измеренного пакета, включая цикл Python и суммирование попаданий. p95 и p99 в CSV относятся к распределению seed-медиан, а не к задержке отдельных запросов.

Ключи / попадания	list, медиана (p25-p75), нс	set, медиана (p25-p75), нс	Парное ускорение
100 / 0%	302.65 (302.25-303.35)	11.54 (11.52-11.56)	26.24x
100 / 50%	237.74 (236.18-239.75)	24.77 (24.58-24.96)	9.58x
100 / 100%	167.37 (165.42-168.95)	21.05 (20.90-21.11)	8.00x
1,000 / 0%	2,874.26 (2,870.62-2,879.66)	17.07 (16.95-17.19)	168.59x
1,000 / 50%	2,166.77 (2,154.86-2,179.83)	25.27 (25.14-25.60)	85.77x
1,000 / 100%	1,465.21 (1,436.06-1,476.12)	21.28 (21.08-21.45)	68.44x
10,000 / 0%	31,708.97 (31,614.36-31,810.41)	12.87 (12.79-13.02)	2456.65x
10,000 / 50%	23,784.66 (23,582.64-24,127.62)	28.99 (28.81-29.52)	822.78x
10,000 / 100%	15,768.29 (15,633.58-15,982.92)	24.47 (24.04-24.71)	642.62x

Проверка основной гипотезы

H0: медианное относительное снижение времени не превышает 20%; H1: превышает 20%. Все 30 seed дали снижение строго выше порога. Односторонний точный знаковый тест: **$p = 9{,}31 \times 10^{-10}$** при α=0,05. H0 отклоняется при предположении независимости seed-единиц в пределах протокола. Только условие 10 000 ключей / 50% попаданий является основным; остальные - исследовательские.

Ускорение рассчитывается сначала внутри каждого seed как list/set, затем берётся медиана парных отношений. Оно может отличаться от отношения двух отдельно рассчитанных медиан.

Научная визуализация

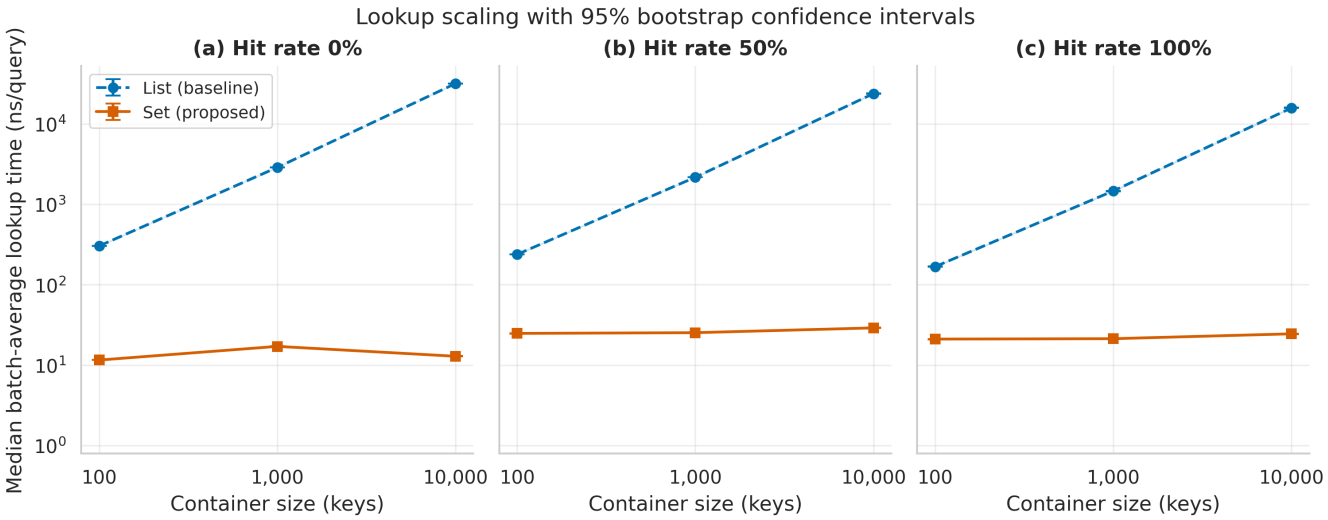


Рисунок 1. Зависимость медианы seed-оценок от размера коллекции при трёх долях попаданий. На обеих осях логарифмический масштаб. Плашки ошибок и затенённые полосы - 95% интервалы по 10 000 перевыборкам 30 seed; некоторые интервалы уже маркеров. list отмечен синими кругами и пунктиром, set - оранжевыми квадратами и сплошной линией. Время list резко возрастает с числом ключей.

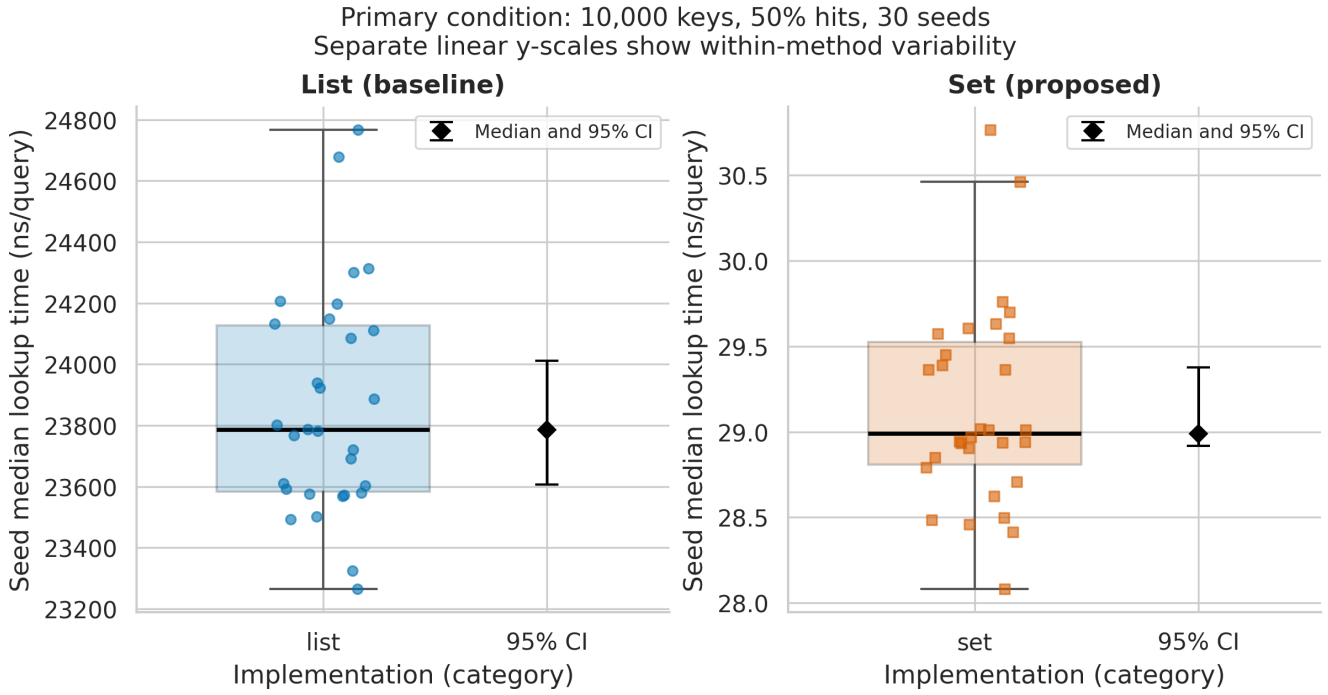


Рисунок 2. Основное условие: 10 000 ключей, 50% попаданий. Показаны все 30 seed-медиан; коробка - p25-p75, линия - медиана, усы - значения в пределах 1,5 IQR. Чёрный ромб и плашки - медиана и её 95% интервал. У панелей **разные линейные шкалы Y**, чтобы показать разброс внутри метода; абсолютные уровни следует сравнивать по рисунку 1 и таблице.

Оба рисунка сохранены отдельно как векторные PDF и PNG 300 DPI. Палитра безопасна для распространённых нарушений цветового зрения, методы различаются также формой маркеров и типом линий.

Доменная модель и точки измерения

Выбрана специализация Software Engineering. Полная C4 component-диаграмма в Mermaid находится в docs/domain_model.md. Она раскрывает один worker-процесс и показывает контроллер, генератор данных, измерители, реализации list/set, буфер и поток сырых логов. Ниже приведена компактная схема границ измерения.



Буфер → контроллер → JSONL → анализ и графики; file I/O вне M2

Метрика	Определение и ограничение
Lookup time	L = T / (Q × B), где T - нс/пакет, Q=1 000, B=10.
Throughput	X = 10^9 / L, запросов/с. Производная того же таймера.
Seed-оценка	Медиана 8 повторов. Итог - медиана по 30 seed.
Ускорение и снижение	S = L_list / L_set; R = 1 - L_set / L_list, внутри seed.
Ошибки	Доля наблюдений с errors > 0, не вероятность ошибки запроса.
Память	Пик tracemalloc: контейнер и Boolean-вектор; не RSS процесса.

Проверка памяти и каждого результата выполняется до прогрева, один раз для метода в worker; значения копируются в его строки. Поэтому warmup не является нетронутым cold start, а повторяющиеся значения памяти не являются независимыми замерами.

Контрольные ограничения

Неуспешные наблюдения: **0 из 4 320** рабочих и **0 из 1 080** прогревочных. Максимум traced allocation по всем условиям: **0.6253 MiB** при лимите 8 MiB. В основном условии list использовал максимум 0.0848 MiB, set - 0.6253 MiB. Нулевой наблюдаемый счётчик ошибок не доказывает отсутствие ошибок для других входных данных.

Обсуждение и ограничения

При основном условии list дал 23,784.66 нс/поиск, set - 28.99 нс/поиск. При этом медиана времени создания set составила 101.96 мкс против 14.89 мкс для list. Выгода повторного поиска не означает выгоду для единственного запроса с учётом построения коллекции.

Проведён один эксперимент на одном компьютере с синтетическими целыми числами. Seed меняет нагрузку, но не создаёт независимые физические машины. Интервалы отражают изменчивость между наборами в этом запуске; они не учитывают изменчивость между компьютерами и повторными сессиями. Открытые приложения и неконтролируемая частота CPU остаются источниками шума.

Равномерное распределение запросов и отсутствие намеренных hash collisions ограничивают переносимость вывода. Исследование не устанавливает универсальное ускорение Python и не распространяется автоматически на строки, базы данных, сетевые сервисы или однократные запросы. set - встроенная реализация, а не новый предложенный алгоритм.

Воспроизводимость и комплект сдачи

Сырые JSONL и метаданные находятся в data/raw/ и data/provenance/. Обработка вынесена в src/process_data.py, визуализация - в src/visualize.py. Выполненный notebooks/01_data_analysis.ipynb содержит 8 последовательных кодовых ячеек с сохранёнными таблицами и рисунками. Bootstrap seed=42. В CSV включены медианы, средние, SD, p25, p75, p95, p99 и 95% интервалы.

Для воспроизведения анализа: установить зависимости из requirements-analysis.txt и выполнить **python src/run_notebook.py** из корня репозитория. Запускается новый kernel; исходные замеры не повторяются. Для нового эксперимента предусмотрена отдельная команда в README с новым выходным каталогом. Исходные файлы защищены от перезаписи.

Пройдены 17 автоматических проверок: корректность инструмента, обработка timeout, сохранность предыдущих результатов, фильтрация прогрева, сохранение ошибок и выбросов, полнота парных данных и воспроизводимость бутстрепа. Графики и PDF проверены визуально. В Git исключены временные окружения, checkpoints и лишние сырые запуски. Комплект предназначен для сдачи как ссылка на публичный репозиторий и этот PDF.

Технические источники

Python 3.12 - perf_counter_ns

NumPy - Generator.choice

C4 model - Component diagram

NBClient - Executing notebooks

Код, анализ и оформление подготовлены с помощью Codex. Индивидуальные вклады участников сверх уже зафиксированных в CONTRIBUTIONS.md не приписываются. Перед сдачей авторам следует проверить понимание методики и выводов.